

ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC BÁCH KHOA
KHOA KHOA HỌC VÀ KỸ THUẬT MÁY TÍNH



Đồ án tổng hợp - hướng kỹ thuật dữ liệu (CO3127)

Report tuần 40
**Thu thập và phân tích dữ liệu
của ứng dụng giải trí Spotify**

Giảng viên hướng dẫn: GV.Dương Huỳnh Anh Đức

Họ tên SV	MSSV	Nhóm - Lớp
Nguyễn Minh Nhật	2312550	2 - L02
Phạm Đình Phương Nam	2312186	2 - L02
Đoàn Mạnh Tất	2313074	2 - L02
Phạm Đức Hoài Nam	2212157	2 - L02

TP. HỒ CHÍ MINH, THÁNG 10/ 2025

Nhiệm vụ công việc

Danh sách phân công ở giai đoạn 1(tuần 37-40)

STT	Họ và tên	Tuần	Nhiệm vụ	Hoàn thành
1	Nguyễn Minh Nhật	37	Tìm hiểu đề tài	100%
		38	Họp online, phân chia nhiệm vụ, phân tích rõ bối cảnh vấn đề của đề tài	
		39	Lấy data từ Kaggle; Dùng Spotify API để làm đầy metadata; ReccoBeats để lấy audio features; Viết report	
		40	Tiền xử lý, khám phá insight dữ liệu	
2	Phạm Đình Phương Nam	37	Tìm hiểu đề tài	100%
		38	Họp online, phân chia nhiệm vụ, phân tích rõ bối cảnh vấn đề của đề tài	
		39	Tìm hiểu nguồn data; Thu thập dữ liệu; Giải quyết vấn đề về data	
		40	Hoàn chỉnh cho thu thập, phân tích dữ liệu, demo code cho nguồn thứ 3; Viết báo cáo, chuẩn bị slide	
3	Đoàn Mạnh Tất	37	Tìm hiểu đề tài	100%
		38	Họp online, phân chia nhiệm vụ, phân tích rõ bối cảnh vấn đề của đề tài	



STT	Họ và tên	Tuần	Nhiệm vụ	Hoàn thành
		39	Tìm hiểu dữ liệu, xử lý vấn đề về dữ liệu	
		40	Viết demo phân tích dữ liệu , làm báo cáo và slide thuyết trình	
4	Phạm Đức Hoài Nam	37	Tìm hiểu đề tài	100%
		38	Họp online, phân chia nhiệm vụ, phân tích rõ bối cảnh vấn đề của đề tài	
		39	Tiền xử lý dữ liệu;Phân tích tương quan dữ liệu	
		40	Demo code, chuẩn bị báo cáo	

Nhận xét từ giảng viên

STT	Họ và tên	Điểm số	Nhận xét
1	Nguyễn Minh Nhật		
2	Phạm Đình Phương Nam		
3	Đoàn Mạnh Tất		
4	Phạm Đức Hoài Nam		

Mục lục

1	Giới thiệu	1
1.1	Tổng quan về Spotify	1
1.2	Vấn đề thực tế – Nhu cầu phân tích dữ liệu Spotify (xu hướng âm nhạc, gợi ý nhạc, phân tích nghệ sĩ)	2
1.2.1	Nhà nghiên cứu âm nhạc và dữ liệu	3
1.2.2	Người dùng và cộng đồng nghe nhạc:	3
1.2.3	Nghệ sĩ và hãng thu âm	3
1.2.4	Doanh nghiệp và tổ chức quảng cáo	3
1.2.5	Kỹ sư dữ liệu và nhà phát triển hệ thống	4
2	Mục tiêu đồ án	4
2.1	Thu thập và tiền xử lý dữ liệu	4
2.2	Thiết kế và xây dựng hệ thống dữ liệu	4
2.3	Xây dựng pipeline xử lý và phân tích dữ liệu	4
2.4	Phân tích và trực quan hóa dữ liệu Spotify	5
2.5	Ứng dụng và mở rộng	5
3	Tìm hiểu và phân tích đặc điểm của nguồn dữ liệu	5
3.1	Nguồn 1: Spotify Top 50 Playlist Songs	6
3.1.1	Giới thiệu dữ liệu	6
3.1.2	Bổ sung dữ liệu:	7
3.1.3	Tiền xử lý	11
3.1.4	Phân tích và tìm insight:	15

1 Giới thiệu

1.1 Tổng quan về Spotify

Spotify là nền tảng phát nhạc trực tuyến hàng đầu thế giới, cung cấp dịch vụ nghe nhạc, podcast và audiobook theo yêu cầu cho hàng trăm triệu người dùng trên toàn cầu. Được ra mắt lần đầu tiên vào năm 2008 tại Thụy Điển, Spotify ra đời với mục tiêu tạo ra một giải pháp hợp pháp, tiện lợi và chống lại tình trạng vi phạm bản quyền âm nhạc trong thời kỳ bùng nổ Internet. Từ đó, Spotify đã nhanh chóng phát triển, trở thành biểu tượng cho sự thay đổi cách con người tiếp cận và thưởng thức âm nhạc.

Spotify hoạt động trên nhiều nền tảng như máy tính, điện thoại thông minh, TV, và các thiết bị IoT. Ứng dụng này hiện có mặt tại hơn 180 quốc gia và vùng lãnh thổ, sở hữu hơn 100 triệu bài hát cùng hơn 5 triệu podcast. Với hơn 600 triệu người dùng hàng tháng, trong đó hơn 240 triệu thuê bao trả phí, Spotify giữ vị trí dẫn đầu trong ngành công nghiệp phát nhạc trực tuyến toàn cầu.




Hình 1.1: Logo Spotify

Không chỉ là một nền tảng âm nhạc, Spotify còn mang theo những giá trị mới mẻ về cá nhân hóa trải nghiệm. Hệ thống đề xuất thông minh dựa trên trí tuệ nhân tạo và dữ liệu lớn mang đến cho người dùng những playlist riêng biệt như Discover Weekly hay

Release Radar. Qua đó, Spotify không chỉ thỏa mãn nhu cầu giải trí mà còn kết nối nghệ sĩ với khán giả, mở rộng ảnh hưởng văn hóa và hỗ trợ sự phát triển của ngành công nghiệp âm nhạc.

Một trong những nét đặc trưng nổi bật của Spotify là các chiến dịch sáng tạo và biểu tượng văn hóa số. Ví dụ, Spotify Wrapped – bản tổng kết hàng năm – đã trở thành hiện tượng toàn cầu, nơi hàng triệu người chia sẻ thói quen nghe nhạc của mình trên mạng xã hội. Bên cạnh đó, Spotify cũng chú trọng vào trải nghiệm đồng bộ qua Spotify Connect, cho phép người dùng dễ dàng phát nhạc trên nhiều thiết bị cùng lúc.



Hình 1.2: Spotify Wrapped

Trong suốt quá trình phát triển, Spotify đã chứng kiến và góp phần tạo nên nhiều dấu ấn lịch sử của ngành nhạc số, thay đổi thói quen thưởng thức âm nhạc của cả một thế hệ. Không chỉ là nơi phát nhạc, Spotify còn là một nền tảng truyền cảm hứng, đưa âm nhạc đến gần hơn với cuộc sống hằng ngày và khẳng định sức mạnh của công nghệ trong việc kết nối con người qua âm nhạc.

1.2 Vấn đề thực tế – Nhu cầu phân tích dữ liệu Spotify (xu hướng âm nhạc, gợi ý nhạc, phân tích nghệ sĩ)

Trong kỷ nguyên số, lượng dữ liệu âm nhạc mà Spotify quản lý và tạo ra mỗi ngày là vô cùng khổng lồ: hàng tỷ lượt nghe, tìm kiếm, thêm vào playlist, chia sẻ và tương tác xã hội. Việc phân tích dữ liệu từ Spotify không chỉ phục vụ mục tiêu thương mại mà còn mang lại nhiều giá trị trong nghiên cứu, phát triển công nghệ và thậm chí là lĩnh vực văn hóa – xã hội. Một số nhóm đối tượng tiêu biểu có nhu cầu sử dụng dữ liệu này như sau:

1.2.1 Nhà nghiên cứu âm nhạc và dữ liệu

- Phân tích xu hướng nghe nhạc theo thời gian, theo khu vực địa lý hoặc theo độ tuổi.
- Nghiên cứu mối liên hệ giữa đặc điểm âm nhạc (tempo, energy, danceability) với mức độ phổ biến.
- Tạo ra các mô hình dự đoán bài hát/ nghệ sĩ có khả năng trở thành xu hướng trong tương lai.

1.2.2 Người dùng và cộng đồng nghe nhạc:

- Khám phá thói quen nghe nhạc cá nhân và so sánh với bạn bè hoặc cộng đồng.
- Tìm kiếm và gợi ý playlist phù hợp với tâm trạng, bối cảnh, hoạt động hàng ngày.
- Theo dõi các bảng xếp hạng như Top 50 Global hay Top 50 theo quốc gia để nắm bắt trào lưu âm nhạc mới.

1.2.3 Nghệ sĩ và hãng thu âm

- Phân tích dữ liệu lượt nghe để đánh giá mức độ thành công của ca khúc, album hay tour diễn.
- Nghiên cứu thị trường mục tiêu: quốc gia, độ tuổi, giới tính của người nghe.
- Tối ưu hóa chiến lược phát hành (ngày ra mắt, thể loại, hợp tác nghệ sĩ) nhằm tối đa hóa doanh thu và mức độ lan tỏa.

1.2.4 Doanh nghiệp và tổ chức quảng cáo

- Sử dụng dữ liệu hành vi người dùng để tối ưu hóa việc phân phối quảng cáo âm thanh và banner.
- Xác định nhóm khách hàng tiềm năng thông qua sở thích âm nhạc, từ đó đưa ra chiến lược tiếp thị hiệu quả hơn.

- Tận dụng dữ liệu thời gian thực để phân tích hiệu quả chiến dịch marketing (ví dụ: chiến dịch gắn liền với sự kiện âm nhạc quốc tế).

1.2.5 Kỹ sư dữ liệu và nhà phát triển hệ thống

- Nhu cầu xử lý big data với tốc độ cao, từ đó yêu cầu hạ tầng dữ liệu mạnh mẽ (Apache Kafka, Spark, Hadoop).
- Đảm bảo tính chính xác, toàn vẹn và bảo mật của dữ liệu khi có hàng trăm triệu người dùng cùng truy cập.
- Xây dựng pipeline phân tích dữ liệu streaming theo thời gian thực, phục vụ cho hệ thống gợi ý cá nhân hóa.

2 Mục tiêu đề án

2.1 Thu thập và tiền xử lý dữ liệu

- Thu thập các dataset về Spotify từ Kaggle, API Sportify, ReccoBeats
- Làm sạch và chuẩn hóa dữ liệu: xử lý giá trị thiếu, định dạng ngày, chuẩn hóa các trường thuộc tính, loại bỏ dữ liệu dư thừa.

2.2 Thiết kế và xây dựng hệ thống dữ liệu

- Thiết kế mô hình dữ liệu quan hệ (ERD, RM) dựa trên các file CSV đã chuẩn hóa.
- Tổ chức dữ liệu vào hệ quản trị CSDL (MySQL,...) nhằm đảm bảo tính toàn vẹn, tối ưu truy vấn và dễ dàng mở rộng.
- Áp dụng các kỹ thuật Data Engineering: indexing, trigger, backup/restore, tối ưu hóa dữ liệu.

2.3 Xây dựng pipeline xử lý và phân tích dữ liệu

- Thiết kế mô hình dữ liệu quan hệ (ERD) dựa trên các file CSV đã chuẩn hóa.
- Tổ chức dữ liệu vào hệ quản trị CSDL (MySQL,...) nhằm đảm bảo tính toàn vẹn, tối ưu truy vấn và dễ dàng mở rộng.

- Áp dụng các kỹ thuật Data Engineering: indexing, trigger, backup/restore, tối ưu hóa dữ liệu.

2.4 Phân tích và trực quan hóa dữ liệu Spotify

- Phân tích xu hướng âm nhạc: sự nổi bật của ca khúc/nghe sĩ, vòng đời của bài hát (Hot/Cold cycle), sự khác biệt giữa các quốc gia.
- Khai thác đặc trưng âm nhạc (danceability, energy, acousticness, valence, tempo, v.v.) để tìm mối liên hệ với độ phổ biến.
- Trực quan hóa dữ liệu qua dashboard (Streamlit/Matplotlib/Seaborn), cho phép người dùng tra cứu bảng xếp hạng, so sánh quốc gia, xem biểu đồ xu hướng.
- còn tìm hiểu để thay đổi hoặc mở rộng

2.5 Ứng dụng và mở rộng

- Hỗ trợ người dùng (sinh viên, nhà nghiên cứu, nghệ sĩ, doanh nghiệp) trong việc khai thác thông tin từ dữ liệu Spotify.
- Đề xuất khả năng mở rộng với Machine Learning như gợi ý bài hát, dự đoán bài hát tiềm năng sẽ vào bảng xếp hạng.
- Nâng cấp hệ thống thành mô hình phân tích dữ liệu streaming thời gian thực (Kafka + Spark) để phục vụ cập nhật liên tục.
- còn tìm hiểu để thay đổi hoặc mở rộng (chọn 1 hướng để phát triển)

3 Tìm hiểu và phân tích đặc điểm của nguồn dữ liệu

Trong quá trình thực hiện đề tài, nhóm đã tiến hành khảo sát và lựa chọn các nguồn dữ liệu liên quan trực tiếp đến lĩnh vực nghiên cứu. Mỗi nguồn dữ liệu đều có những đặc trưng riêng về cấu trúc, dung lượng, cũng như mức độ phù hợp với yêu cầu của bài toán. Việc phân tích đặc điểm của từng nguồn giúp nhóm:

- Đánh giá tính tin cậy và độ bao phủ của dữ liệu.
- Hiểu rõ cấu trúc, định dạng, và mối quan hệ giữa các thuộc tính.

- Xác định những vấn đề cần tiền xử lý (dữ liệu thiếu, dữ liệu nhiễu, trùng lặp, ...).
- Đề ra phương án tích hợp và khai thác hiệu quả cho hệ thống.

Dưới đây là phân tích chi tiết từng nguồn dữ liệu mà nhóm sử dụng :

3.1 Nguồn 1: Spotify Top 50 Playlist Songs

- **Link dataset:** <https://www.kaggle.com/datasets/anxods/spotify-top-50-playlist-songs-anxods>
- **Link github:** <https://github.com/minhnhut273/spotify-data-project>

3.1.1 Giới thiệu dữ liệu

Tổng quan

- Bộ dữ liệu cung cấp thông tin bài hát nằm trong bảng xếp hạng Top 50 của Spotify của một số quốc gia gồm 9 nước (United States, Spain, United Kingdom, Italy, France, Mexico, Argentina, Japan, South Korea) và 1 bảng xếp hạng chung top 50 trên thế giới.
- Phạm vi dữ liệu ngoài vị trí địa lý còn về mặt thời gian bộ dataset cung cấp nằm trong khoảng 05/2023 đến 11/2024.

Một số đặc trưng ban đầu:

- **date:** Ngày thu thập dữ liệu hoặc ngày xếp hạng.
- **position:** Vị trí của bài hát trong bảng xếp hạng Top 50.
- **song:** Tên bài hát.
- **artist:** Tên nghệ sĩ hoặc nhóm nghệ sĩ chính.
- **popularity:** Chỉ số phổ biến (Spotify popularity score, 0–100).
- **duration_ms:** Độ dài bài hát tính bằng mili-giây.

- **album_type**: Loại album chứa track này (ví dụ: album, single, compilation).
- **total_tracks**: Tổng số track trong album chứa bài hát đó.
- **release_date**: Ngày phát hành album (chứa bài hát này).
- **is_explicit**: Cho biết bài hát có nội dung 18+ hay không.
- **album_cover_url**: Link ảnh bìa album.

```
Thông tin chi tiết về DataFrame:
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 27800 entries, 0 to 27799
Data columns (total 11 columns):
#   Column                Non-Null Count  Dtype
---  ---
0   date                  27800 non-null  object
1   position              27800 non-null  int64
2   song                  27800 non-null  object
3   artist                27800 non-null  object
4   popularity            27800 non-null  int64
5   duration_ms           27800 non-null  int64
6   album_type            27800 non-null  object
7   total_tracks          27800 non-null  int64
8   release_date          27800 non-null  object
9   is_explicit           27800 non-null  bool
10  album_cover_url       27800 non-null  object
dtypes: bool(1), int64(4), object(6)
memory usage: 2.1+ MB
None

kích thước
(27800, 11)
```

Hình 3.1: Đặc điểm chung của các dataset

=> Kết quả có được 10 file **spotify-streaming-top-50-region.csv** có đặc điểm như hình trên

3.1.2 Bổ sung dữ liệu:

- Dùng Spotify API để hoàn thiện metadata



- **Giới thiệu API:** Spotify Web API là dịch vụ do Spotify cung cấp. Cho phép lập trình viên truy cập dữ liệu nhạc số trên Spotify, hoạt động qua HTTP request (RESTful API).
- **Mục đích:** Do nhóm nhận thấy các trường dữ liệu của dataset gốc chưa cung cấp đầy đủ, chi tiết về metadata của dữ liệu nên nhóm quyết định sử dụng API này để hoàn thiện nó.
- **Các trường có thể thêm gồm:**
 - **track_id:** ID duy nhất của bài hát trên Spotify.
 - **album_id:** ID duy nhất của album chứa bài hát.
 - **uri:** Định danh Spotify URI (dùng để mở trực tiếp trong Spotify).
 - **href:** Link API đến resource (track/album) trong Spotify Web API.
 - **external_url:** Link mở trên Spotify (dành cho người dùng).
 - **external_ids:** Thông tin định danh khác (ví dụ ISRC – mã nhận dạng bản ghi).
 - **disc_number:** Số đĩa (trong trường hợp album nhiều đĩa).
 - **track_number:** Vị trí bài hát trong album/đĩa.
 - **release_date_precision:** Độ chính xác của ngày phát hành (có thể là year, month, hoặc day).
 - **is_playable:** Cho biết bài hát có thể phát được không (True/-False).
 - **linked_from:** Nếu bài hát được liên kết từ một track khác (ví dụ bản sao trong album khác).
 - **preview_url:** Link nghe thử 30 giây bài hát.
 - **restrictions:** Các giới hạn (ví dụ chỉ phát được ở một số quốc gia).

- **available_markets**: Danh sách quốc gia mà track này có sẵn.
- **genres**: Thể loại âm nhạc nghệ sĩ theo đuổi.

```
[5 rows x 26 columns]

Thông tin chi tiết về DataFrame:
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 27800 entries, 0 to 27799
Data columns (total 26 columns):
#   Column                                Non-Null Count  Dtype
---  -
0   date                                  27800 non-null  object
1   position                              27800 non-null  int64
2   song                                  27800 non-null  object
3   artist                                27800 non-null  object
4   popularity                            27800 non-null  int64
5   duration_ms                           27800 non-null  int64
6   album_type                            27800 non-null  object
7   total_tracks                          27800 non-null  int64
8   release_date                          27800 non-null  object
9   is_explicit                           27800 non-null  bool
10  album_cover_url                       27800 non-null  object
11  track_id                               27781 non-null  object
12  album_id                               27781 non-null  object
13  release_date_precision                 27781 non-null  object
14  preview_url                           0 non-null      float64
15  external_url                           27781 non-null  object
16  is_playable                           0 non-null      float64
17  available_markets                      27781 non-null  object
18  disc_number                           27781 non-null  float64
19  track_number                           27781 non-null  float64
20  href                                   27781 non-null  object
21  uri                                    27781 non-null  object
22  external_ids                           27781 non-null  object
23  linked_from                            0 non-null      float64
24  restrictions                           0 non-null      float64
25  genres                                 14097 non-null  object
dtypes: bool(1), float64(6), int64(4), object(15)
memory usage: 5.3+ MB
```

Hình 3.2: Các trường sau khi thêm

=> Kết quả có được các file **..with-meta.csv** có đặc điểm như hình trên

- **Hạn chế**: Tuy nhiên, do một số chính sách mới ra cuối năm 2024 của Spotify dẫn đến các nhóm người không thể truy cập được một số nội dung (chart, lyric,...) trong đó có audio feature - nguồn dữ liệu mà nhóm quan tâm.

- Dùng ReccoBeats để bổ sung audio feature:

- **Giới thiệu API:** Recobeats API là một dịch vụ bên thứ ba giúp lấy dữ liệu nhạc từ Spotify (playlist, audio features, metadata) và dùng cho phân tích hoặc gợi ý nhạc. Tuy nhiên nó không phải API chính thức.
- **Các trường có thể thêm:**
 - **href:** Link Spotify đến bài hát (https://open.spotify.com/track/<track_id>). Dùng để mở hoặc kiểm tra thủ công.
 - **acousticness:** Mức độ “mộc” (0.0–1.0). Cao => nhạc acoustic, ít electronic.
 - **danceability:** Độ dễ nhảy (0.0–1.0). Cao => dễ nhảy, dựa trên nhịp, groove, tempo.
 - **energy:** Cường độ/độ bốc (0.0–1.0). Liên quan tới tempo, loudness, mật độ âm thanh.
 - **instrumentalness:** Khả năng không lời (0.0–1.0). >0.5 thường là nhạc cụ/không lời.
 - **key:** Tông nhạc (0–11, -1 nếu không phát hiện). Ví dụ: 0=C, 1=C#/Db, ... 11=B.
 - **liveness:** Dấu hiệu biểu diễn live (0.0–1.0). >0.8 thường là bản live.
 - **loudness:** Độ ồn trung bình (dB, -60 => 0). Giá trị càng gần 0 càng to.
 - **mode:** Điệu thức: 1 = Major (tươi sáng), 0 = Minor (trầm buồn).
 - **speechiness:** Tỷ lệ lời nói (0.0–1.0). >0.66: chủ yếu là nói; 0.33–0.66: rap/spoken; <0.33: chủ yếu là nhạc.
 - **tempo:** Nhịp độ (BPM, 0–250). Nhạc phổ biến: 60–200 BPM.

- **valence**: Độ “tươi vui”/tích cực (0.0–1.0). 0.0 = buồn/tối, 1.0 = vui/sáng.

```
Thông tin chi tiết về DataFrame:  
<class 'pandas.core.frame.DataFrame'>  
RangeIndex: 27692 entries, 0 to 27691  
Data columns (total 13 columns):  
#   Column                Non-Null Count  Dtype  
---  ---  
0   track_id              27692 non-null  object  
1   href                  26512 non-null  object  
2   acousticness          26512 non-null  float64  
3   danceability           26512 non-null  float64  
4   energy                 26512 non-null  float64  
5   instrumentalness       26512 non-null  float64  
6   key                    26512 non-null  float64  
7   liveness               26512 non-null  float64  
8   loudness               26512 non-null  float64  
9   mode                   26512 non-null  float64  
10  speechiness            26512 non-null  float64  
11  tempo                  26512 non-null  float64  
12  valence                 26512 non-null  float64  
dtypes: float64(11), object(2)  
memory usage: 2.7+ MB
```

Hình 3.3: Bảng đặc trưng

=> Kết quả có các file `..with-audio.csv` có đặc điểm như hình trên

3.1.3 Tiền xử lý

- Xử lý Metadata:

- Giữ lại một số trường cần thiết:

- **date** — phân tích theo thời gian.
- **position** — vị trí xếp hạng trong Top 50.
- **song** — tên bài hát.
- **artist** — tên nghệ sĩ.
- **track_id** — khóa chính để join với with-audio.
- **popularity** — đo mức độ phổ biến.

- **duration_ms** — độ dài bài hát (có thể phân tích thêm).
- **is_explicit** — xem tỷ lệ nhạc explicit.
- **album_id** — phân tích theo album (nếu cần).
- **release_date** — phân tích bài mới/cũ.
- **genres** — phân tích xu hướng thể loại.
- Bỏ các trường không cần thiết còn lại

- **Xử lý Missing Values (Data Cleaning):**

- **Mục tiêu:** đảm bảo dữ liệu không còn NaN ở các cột quan trọng.
- **track_id, extttalbum_id và genres** : nếu thiếu → điền "unknown_track", "unknown_album" và "unknown".
- **release_date**:
 - * Nếu chỉ có năm → ghép "YYYY-01-01".
 - * Nếu NaN → dùng "YYYY-01-01" dựa trên năm nhỏ nhất trong cột date.

- **Chuẩn hóa dữ liệu (Standardization):**

- **Mục tiêu:** đưa dữ liệu về format thống nhất để dễ phân tích.
- **date & release_date**:
 - * Convert toàn bộ sang **datetime** (YYYY-MM-DD).
- **genres**:
 - * Nếu có nhiều genre → lấy genre đầu tiên tạo cột **main_genre**.
- **is_explicit**: convert về 0/1 (boolean → int).

=> **Kết quả:** tạo được các file ...with-meta-clean.csv .

- Xử lý file audio:

• Bước 1. Kiểm tra & xử lý Missing Values:

- track_id, href: giữ nguyên (định danh và link).
- Các đặc trưng [0–1] (danceability, energy, valence, acousticness, instrumentalness, liveness, speechiness):
 - * Nếu NaN → thay bằng *median* (hoặc giá trị phổ biến nhất).
 - * Sau đó clip về [0,1].
- tempo:
 - * Nếu NaN hoặc bất thường (< 30 hoặc > 250) → thay bằng median.
- loudness:
 - * Nếu NaN hoặc bất thường (< -60 hoặc > 0) → thay bằng median.
- mode (0/1): nếu NaN → điền giá trị chiếm đa số trong cột.
- key:
 - * Nếu -1 hoặc NaN → thay bằng giá trị gần nhất (forward/backward fill hoặc mode).

• Bước 2. Chuẩn hóa dữ liệu (Standardization):

- Các đặc trưng [0–1] (danceability, energy, valence, acousticness, instrumentalness, liveness, speechiness):
 - * Clip về [0,1], giữ nguyên cột gốc (không thêm).
- tempo:
 - * Thêm $\text{tempo_norm} = (\text{tempo} - 30) / (250 - 30)$.
- loudness:

- * Thêm `loudness_norm = (loudness + 60)/60`.
- `key`:
 - * Thêm cột mới `key_name` (C, C#, D, ..., B) và Đảm bảo không còn "unknown" (đã thay bằng giá trị hợp lệ).

```
Thông tin chi tiết về DataFrame:
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 775 entries, 0 to 774
Data columns (total 16 columns):
#   Column                Non-Null Count  Dtype
---  -
0   track_id              775 non-null   object
1   href                  775 non-null   object
2   acousticness          775 non-null   float64
3   danceability           775 non-null   float64
4   energy                 775 non-null   float64
5   instrumentalness       775 non-null   float64
6   key                    775 non-null   float64
7   liveness               775 non-null   float64
8   loudness               775 non-null   float64
9   mode                   775 non-null   int64
10  speechiness            775 non-null   float64
11  tempo                  775 non-null   float64
12  valence                 775 non-null   float64
13  tempo_norm             775 non-null   float64
14  loudness_norm          775 non-null   float64
15  key_name                775 non-null   object
dtypes: float64(12), int64(1), object(3)
memory usage: 97.0+ KB
```

Hình 3.4: Đặc trưng chung


=> **Kết quả:** ghi đè vào các file `...with-audio.csv` với các đặc trưng như trên.

3.1.4 Phân tích và tìm insight:

-Công cụ khám phá: Jupyter Notebook

1. Bức tranh toàn diện về vòng đời âm nhạc trên BXH

• 1.1 Số bài hát mới phát hành theo năm




Hình 3.5: Track mới phát hành theo năm

– Kết luận:

- Trước năm 2015: số lượng track mới trên BXH rất ít, tăng trưởng chậm
- Giai đoạn 2015–2020: bắt đầu có xu hướng tăng nhưng chưa bùng nổ.
- Từ 2020 trở đi: số lượng track mới tăng vọt, đặc biệt 2023–2024 đạt đỉnh. Xuất hiện ở hầu hết quốc gia, mạnh nhất tại Mỹ & Argentina, trong khi Hàn Quốc và Nhật Bản nổi bật nhờ K-pop và J-pop.
- Streaming và toàn cầu hoá đã tạo ra “làn sóng bùng nổ” sản xuất nhạc mới sau 2020

• 1.2 Tuổi thọ bài hát trên bảng xếp hạng:




Hình 3.6: 1.2 Tuổi thọ các bài hát trên BXH


– Kết luận:

- Phần lớn bài hát có tuổi thọ ngắn, đa số bài hát chỉ trụ được dưới 10 tuần trên BXH => đặc trưng chung của BXH Top 50: hit bùng nổ nhanh nhưng cũng dễ rơi khỏi bảng.
- Vẫn tồn tại nhóm nhỏ có tuổi thọ dài (> 50 tuần), kéo dài đến 300–500 tuần. Những bài này thường là siêu hit toàn cầu hoặc gắn liền với văn hóa.
- So sánh giữa các nước và thế giới: Ở cấp quốc gia, tuổi thọ thường ngắn hơn => thị trường có tính “nóng hổi”. Ở cấp thế giới, xuất hiện nhiều bài hát có tuổi thọ cực dài => tính bền vững và lan tỏa rộng.


• 1.3 Độ biến động (volatility) trên BXH




USA




UK




Korea



UK



World



World

Hình 3.7: 1.2 Độ biến động tổng quan trên BXH


– Kết luận:

- Mức biến động cao ở nhiều thị trường lớn, Mỹ, Anh thường có volatility > 20–30% trong nhiều giai đoạn. Cho thấy cạnh tranh gay gắt, các ca khúc nhanh chóng leo hạng và rời BXH
- Một số thị trường ổn định hơn Nhật, Ý, Tây Ban Nha có volatility thấp hơn (chủ yếu < 15%). Điều này phản ánh thị hiếu nghe nhạc ổn định, ít thay đổi đột ngột theo xu hướng.
- Đặc thù mùa vụ và sự kiện âm nhạc: Các đỉnh biến động thường


rơi vào dịp cuối năm, mùa lễ hội. Ví dụ: giai đoạn cuối 2023 và giữa 2024 có nhiều peak volatility (đỉnh) đồng loạt ở nhiều nước.

2. Nghệ sĩ và Bài hát


• 2.1 Top 10 nghệ sĩ phổ biến




USA



UK



Korea



World


Hình 3.8: Top 10 nghệ sĩ nổi bật nhất

– Kết luận:


- Nhìn chung đa số quốc gia có nghệ sĩ nội địa thống trị: ví dụ Emilia, Luck Ra (Argentina), Werenoi (France), Geolier, Tedua (Italy), Mrs. GREEN APPLE, YOASOBI (Japan), Peso Pluma (Mexico), Lim Young Woong, BTS members, NewJeans (Korea).
- Riêng thị trường Âu-Mỹ vẫn nổi bật với những ngôi sao toàn cầu: Taylor Swift, Billie Eilish, Drake, Bad Bunny, KAROL G... thường xuyên góp mặt cả ở BXH quốc gia và World.

- Có sự khác biệt rõ rệt giữa thị hiếu nội địa và toàn cầu: Nhật, Hàn Quốc chủ yếu nghệ sĩ bản địa; trong khi BXH World và Mỹ/UK có nhiều nghệ sĩ đa quốc gia.

• 2.2 Bài hát theo độ hot



Hình 3.9: Top 10 bài hát trụ nổi nhất



World


Hình 3.10: Top 5 bài hát trụ lâu nhất

– Kết luận:


- Top 10 bài hát phổ biến: mỗi quốc gia có “quốc ca nội địa” riêng , trong khi BXH World lại nổi bật với các siêu hit toàn cầu .
- Top 5 bài hát trụ lâu nhất : Cho thấy sự khác biệt giữa các thị trường: US/UK có những bản hit lâu bền, Hàn Quốc ghi dấu với loạt K-pop nổi bật, còn các nước Mỹ Latin có nhiều ca khúc trụ lâu thuộc dòng nhạc địa phương. Trên BXH World, một số siêu hit quốc tế thể hiện sức hút bền vững, duy trì thứ hạng cao trong nhiều tháng.
- So sánh quốc gia – thế giới cho thấy: bài hát nội địa thường nổi trong nước nhưng ít khi bền vững toàn cầu, ngược lại siêu hit quốc tế có sức lan tỏa rộng và trụ lâu hơn

3. Thể loại


• 3.1 Top 10 thể loại phổ biến




Argentina



Korea



Spain




World

Hình 3.11: Top 10 thể loại nổi bật nhất


– **Kết luận:**

- Mỗi quốc gia có thể loại bản địa thống trị, ví dụ: Argentina (Argentine trap, RKT, cuarteto), Japan (J-pop, Anime, J-rock), ..
- Sự khác biệt văn hoá rõ rệt: Nhật – Hàn nghiêng về nhạc bản địa (J-pop, K-pop), Mexico – LATAM mạnh về reggaeton/corrido, còn Âu-Mỹ giữ vị thế với pop/rap.
- Xu hướng toàn cầu: Một số thể loại vượt biên giới mạnh mẽ (reggaeton, trap, pop, rap) => lan toả sang nhiều thị trường khác nhau.


• **3.1 Xu hướng thể loại theo thời gian**




Mexico



Japan



France




World

Hình 3.12: Top 10 thể loại nổi bật nhất


– **Kết luận:**

- Genre bản địa áp đảo ổn định: J-pop (Japan), K-pop/K-ballad (Korea), French rap (France), Italian trap (Italy).


- Đa dạng nhất: Mexico – sự kết hợp của corrido, banda, tumbados, reggaeton, cumbia norteña.
- Khép kín: Nhật và Hàn hầu như chỉ nghe nhạc nội địa.
- Thể loại Latin (reggaeton, corrido, trap latino) tăng mạnh tại Argentina, Mexico, Spain và có sức lan tỏa sang thị trường quốc tế.
- Thể loại mùa vụ như Christmas nổi bật ở US/UK, tạo các đỉnh ngắn hạn cuối năm.
- Thị trường toàn cầu (World) cho thấy sự kết hợp của reggaeton, K-pop và pop/rap, phản ánh sự giao thoa văn hoá âm nhạc xuyên biên giới.




USA



UK



Spain



World

Hình 3.13: Độ đa dạng theo tuần





- **Kết luận:**
- Khác biệt thị trường: US và World đa dạng nhất (10–22 genre/tuần), trong khi Nhật, Hàn, Ý khá tập trung (5–12 genre, chủ yếu

J-pop, K-pop, Italian trap).

- Xu hướng mùa vụ: US/UK xuất hiện nhiều genre phụ cuối năm (Christmas, country, grime), còn Nhật/Hàn ổn định quanh 5–8 genre.
- Mỹ Latin (Argentina, Mexico, Spain): trung bình 8–15 genre, xoay quanh reggaeton, corrido, trap latino => ít bùng nổ thể loại mới.
- Nhật Bản & Hàn Quốc: số genre unique thấp và ổn định (5–8/tuần), gần như bị áp đảo bởi J-pop (Japan) và K-pop/K-ballad (Korea).

4. Đặc trưng âm nhạc

• 4.1 Đặc trưng energy




Hình 3.14: Đặc trưng energy


– **Kết luận:**

- Tồn tại sự khác biệt rõ rệt về mức năng lượng ưa chuộng giữa các thị trường, phản ánh sự đa dạng trong văn hóa nghe nhạc và đặc tính thể loại bản địa.
- Phân cực rõ ràng giữa hai nhóm thị trường:
 - * Nhóm năng lượng cao & đa dạng: Hầu hết các quốc gia như Argentina, France, UK, USA có phân phối energy. trải dài từ 0.2 đến 1.0 => thị hiếu âm nhạc tại đây rất đa dạng, chấp nhận cả những bài nhạc trầm lắng (energy thấp) lẫn những bài cực kỳ sôi động (energy cao).
 - * Nhóm năng lượng trung bình & "ôn hòa": Italy và Spain có phân phối giới hạn trong khoảng 0.2 đến 0.9 => top âm nhạc tại đây có xu hướng thiếu vắng những bài hát có mức năng lượng cực cao, phù hợp với các thể loại mang tính chất nhẹ nhàng, êm dịu hơn như Pop, Ballad, hoặc Latin truyền thống.
- Japan là trường hợp đặc biệt: Phân phối energy của Nhật bắt đầu từ 0.3 đến 1.0. Ngưỡng năng lượng tối thiểu cao hơn => ưa chuộng những bản nhạc có tiết tấu nhanh và sôi động ngay từ đầu, ít các bài hát có nhịp độ chậm và trầm buồn
- Thị trường toàn cầu (World) là sự kết hợp: Phân phối energy của World phủ rộng từ 0.2 đến 1.0, phản ánh chính xác việc nó là sự tổng hòa của tất cả các thị trường, thể hiện sự đa dạng và toàn diện nhất về mức năng lượng.


• **4.2 Đặc trưng tempo**




UK



Italy



Argentinian



World

Hình 3.15: Đặc trưng tempo


– Kết luận:

- Tồn tại sự tương đồng lớn về phân phối nhịp độ giữa các thị trường chủ chốt. Các nước như Argentina, Mexico, Nhật Bản (Japan) và Hàn Quốc (South Korea) có phân phối tempo gần như trùng khớp, tập trung cao ở khoảng 100-140 BPM. Điều này cho thấy một "công thức nhịp độ toàn cầu" cho các bản hit.
- Một số thị trường có phạm vi nhịp độ rộng hơn. Các nước như Italy, Tây Ban Nha (Spain), Pháp (France), Anh (UK), Mỹ (USA) và thị trường Thế giới (World) có phân phối trải dài từ khoảng 60 BPM đến 180-200 BPM. Sự đa dạng này phản ánh tính chất âm nhạc phong phú, bao gồm cả những bản ballad chậm rãi (tempo

thấp) lẫn những bài EDM hoặc Rock sôi động (tempo cao).

- Nhịp độ trung bình (80-140 BPM) là phổ biến nhất trên toàn cầu, phù hợp với các thể loại nhạc phổ biến như Pop, Rap và Dance. Phân phối của thị trường Thế giới (World) một lần nữa đóng vai trò là trung bình chuẩn mực, tổng hòa xu hướng từ tất cả các thị trường thành phần.

• 4.3 Đặc trưng valence




Hình 3.16: Đặc trưng valence

– Kết luận:


- Đa số các thị trường có phân phối valence tập trung ở mức trung bình đến cao (0.4 - 0.8). Điều này cho thấy xu hướng chung toàn cầu là ưa chuộng những bài hát mang cảm xúc tích cực, vui tươi.

- Tây Ban Nha (Spain) và Nhật Bản (Japan) là hai thị trường nổi bật với xu hướng yêu thích các bản nhạc cực kỳ tích cực. Phân phối valence của hai nước này lệch hẳn về phía giá trị cao (0.8 - 1.0), với tần suất cực lớn. Điều này đặc biệt phù hợp với các thể loại sôi động, tươi vui như Reggaeton (Tây Ban Nha) và J-pop (Nhật Bản).
- Các thị trường Âu-Mỹ (Pháp, Italy, Anh, Mỹ) có phân phối cân bằng và đa dạng hơn. Phân phối của họ trải rộng từ 0.0 đến 1.0, cho thấy sự chấp nhận đối với cả những bài hát có cảm xúc trầm lắng, u sầu (valence thấp) bên cạnh những bài hát vui vẻ. Điều này phản ánh thị hiếu âm nhạc đa chiều và có chiều sâu.


• 4.4 Đặc trưng danceability




Spain



Korea



USA



World


Hình 3.17: Đặc trưng danceability

– **Kết luận:**

- Nhóm ưa chuộng tính nhảy múa rất cao: Các quốc gia như Argentina, Italy, Japan, Mexico và Tây Ban Nha (Spain) có phân phối danceability rất hẹp, tập trung ở khoảng 0.6 - 0.9. Điều này cho thấy các bài hát ở đây gần như bắt buộc phải có nhịp điệu dễ nhảy theo, phù hợp với các thể loại như Reggaeton, Latin Pop hay EDM.
- Nhóm linh hoạt hơn: Các thị trường Pháp (France), Hàn Quốc (South Korea), Anh (UK), Mỹ (USA) và Thế giới (World) có phân phối rộng hơn, từ 0.2 đến 1.0. Mặc dù vẫn nghiêng về các bài hát dễ nhảy, họ vẫn chấp nhận những bài hát ít tính nhảy múa hơn (ví dụ: ballad, nhạc acoustic), cho thấy thị hiếu đa dạng.
- Phân phối của thị trường Thế giới (World) cho thấy sự cân bằng, nhưng vẫn nghiêng nhiều về nhóm các bài hát có danceability cao, chứng tỏ đây là một xu hướng chủ đạo.

5. So sánh nhóm

• 5.1 Tỷ lệ Explicit






Hình 3.18: So sánh tỷ lệ Explicit

– **Kết luận:**

- Tồn tại sự khác biệt văn hóa cực kỳ lớn giữa các thị trường trong việc chấp nhận nội dung explicit.
- Nhật Bản và Hàn Quốc với tỷ lệ bài hát clean áp đảo tuyệt đối ($> 90\%$). Điều này cho thấy một tiêu chuẩn văn hóa và giải trí rất khắt khe, phù hợp với các thể loại nhạc đại chúng như J-pop và Anime.
- Các thị trường châu Á và châu Âu thể hiện sự phân cực rõ rệt:
- Argentina là thị trường có tỷ lệ bài hát explicit cao nhất (68.3%), cho thấy sự thống trị của các thể loại như Argentine Trap và Reggaeton, nơi nội dung explicit là một phần của văn hóa âm nhạc.
- Các thị trường lớn còn lại (Italy, Mexico, Spain, UK, USA, World) có tỷ lệ gần như cân bằng ($50/50$). Điều này cho thấy sự chấp nhận và cạnh tranh song hành giữa hai dòng nhạc, phản ánh sự đa dạng và phân hóa trong thị hiếu của người nghe.

● **5.2 Solo vs Colab**





Hình 3.19: So sánh tỷ lệ Explicit

– **Kết luận:**

- Tỷ lệ bài hát Solo chiếm ưu thế tuyệt đối trên toàn cầu => nghệ sĩ cá nhân vẫn có sức hút và khả năng thống trị các bảng xếp hạng lớn.
- Tồn tại sự khác biệt lớn về văn hóa âm nhạc giữa các thị trường:
 - * Nhật Bản và Hàn Quốc là thị trường đề cao tính cá nhân rõ rệt nhất, với tỷ lệ bài hát Solo chiếm tới 95.5 %. Điều này phù hợp với đặc trưng của J-pop, K-pop, nơi các nghệ sĩ solo thường được xây dựng hình tượng mạnh mẽ.
 - * Các thị trường Mỹ Latin (Argentina, Mexico, Tây Ban Nha) có tỷ lệ Collab (hợp tác) cao nhất, dao động từ 37 % đến 46%. Điều này phản ánh đặc tính cộng đồng và xu hướng kết hợp trong các thể loại âm nhạc phổ biến tại đây như Reggaeton, Latin Trap.
 - * Các thị trường Âu-Mỹ (Mỹ, Anh, Pháp, Italy) có tỷ lệ Solo rất cao (từ 69.7% đến 87.3%), cho thấy sự thống trị của các ngôi sao solo trong làng nhạc đại chúng.



- Ở Thế giới, Bài hát Solo chiếm ưu thế rõ rệt (82.0%), cho thấy sức hút và khả năng thống trị bảng xếp hạng toàn cầu của các nghệ sĩ cá nhân.